

Отчёт по промпт-инженерии: Titanic — Machine Learning from Disaster

Датасет: Titanic — Machine Learning from Disaster

Ссылка: kaggle.com/competitions/titanic/data

Модель: Claude Sonnet (claude-sonnet-4-6)

Это учебный датасет с данными о пассажирах «Титаника» и фактом выживания (целевой признак **Survived**). В тренировочной выборке **891 строка** и **12 столбцов**, содержащих демографию, класс билета, стоимость, порт посадки и другие признаки. Данные частично неполные — в первую очередь колонки **Age** (177 пропусков) и **Cabin** (687 пропусков), что делает их удобными для практики EDA и предобработки.

Промпт 1: Понимание структуры данных

Текст промпта:

Ты — помощник по анализу данных. Я работаю с датасетом Titanic (train.csv из Kaggle). Вот результат **df.head(5)** и **df.info()**. Скажи: 1) какие признаки категориальные/числовые/идентификаторы, 2) какая цель, 3) где пропуски и насколько критично, 4) что бы ты проверил первым делом в EDA. Отвечай структурированно, но без кода.

df.head(5):

#	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.0	1	0
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0

df.info():

RangeIndex: 891 entries, 0 to 890

Data columns (total 12 columns):

#	Column	Non-Null Count	Dtype
0	PassengerId	891 non-null	int64
1	Survived	891 non-null	int64
2	Pclass	891 non-null	int64
3	Name	891 non-null	str
4	Sex	891 non-null	std
5	Age	714 non-null	float64
6	SibSp	891 non-null	int64
7	Parch	891 non-null	int64
8	Ticket	891 non-null	str
9	Fare	891 non-null	float64
10	Cabin	204 non-null	str
11	Embarked	889 non-null	str

Ответ LLM:

- **Типы признаков:** Целевая переменная — **Survived** (0/1, бинарная классификация). Идентификатор — **PassengerId**. Числовые: **Age**, **Fare**, **SibSp**, **Parch**. Порядковая категория: **Pclass**. Категориальные: **Sex**, **Embarked**, **Ticket**, **Cabin**, **Name**.
- **Пропуски:** **Age** — ~20% (важно, связан с выживаемостью, нужна импутация); **Cabin** — >75% (лучше создать бинарный флаг «каюта известна/неизвестна»); **Embarked** — 2 строки (заполнить модой).
- **Первые шаги EDA:** баланс классов, связь **Survived** с **Sex/Pclass/Age/Fare**, проверка выбросов, анализ пропусков на случайность, извлечение титула из **Name**.

Мой комментарий:

В целом согласен с разбором: особенно полезна мысль, что **Pclass** скорее порядковая категория, а **Name** лучше не кодировать целиком, а извлекать титул — это действительно даёт хороший дополнительный признак. Я также заметил из реального **df.info()**, что **Cabin** пропущен у 687 из 891 строк (почти 77%) — это намного серьезнее, чем кажется на первый взгляд, и LLM правильно предложила создать бинарный флаг вместо попытки использовать сырое значение. Отдельно я бы уточнил про **Ticket** — у него слишком много уникальных значений и неочевидный формат, поэтому неясно, стоит ли тратить на него время. Ещё полезно было бы сразу попросить подсказку, как проверить «не случайность» пропусков по **Age** через таблицу сопряжённости с **Pclass** и **Sex**.

Промпт 2: Поиск трендов (выживаемость по полу/классу)

Текст промпта:

Я посчитал выживаемость по полу и классу на Titanic. Вот агрегированная таблица (значения — доля выживших):

Sex=female:	Pclass1=0.97	Pclass2=0.92	Pclass3=0.50
Sex=male:	Pclass1=0.37	Pclass2=0.16	Pclass3=0.14

Объясни, какие тренды тут видно, какие гипотезы это порождает, и как бы ты это визуализировал (без кода). Также предупреди, какие ошибки интерпретации тут возможны.

Ответ LLM:

- **Пол — сильнейший фактор:** во всех классах женщины выживают заметно чаще мужчин. Разрыв особенно велик во 2–3 классе.
- **Класс важен внутри каждого пола:** у женщин 1 и 2 класс близки (0.97/0.92), в 3 классе резкое падение до 0.50. У мужчин 1 класс лучше (0.37), 2 и 3 очень низкие и близкие (0.16/0.14).
- **Гипотезы:** приоритет эвакуации «женщины и дети — первыми», физический доступ к шлюпкам по палубам, социальные барьеры между классами.
- **Визуализация:** тепловая карта 2×3 (пол × класс, цвет — доля) или группированная столбчатая диаграмма с подписями размеров групп.
- **Ошибки интерпретации:** игнорирование размеров групп, смешение корреляции и причинности, скрытые переменные (возраст, Embarked), эффект Симпсона.

Мой комментарий:

Ответ полезный и по делу: я как раз видел в реальных данных, что у женщин в 1–2 классе почти все выжили, а у мужчин в 2–3 классе — почти никто. Интересная деталь, которую я заметил сам: у мужчин 2 и 3 класса доли почти одинаковые (0.16 и 0.14) — несмотря на разные условия проезда. Это наводит на мысль, что для мужчин класс играл гораздо меньшую роль, чем для женщин, и основным барьером была именно половая принадлежность. Ещё мне не хватило конкретики по размерам групп — хотелось бы знать, сколько именно пассажиров в каждой ячейке, чтобы понимать, насколько надёжны эти доли, особенно для женщин 1 класса (0.97 — высокая доля, но сколько там наблюдений?). В следующий раз попрошу LLM сразу добавлять размеры выборки рядом с долями.

Промпт 3: Обнаружение аномалий

Текст промпта:

Я заметил в Titanic возможные аномалии: у **Fare** есть очень большие значения (максимум 512.33 при среднем ~32), а в **Age** есть 177 пропусков. Предложи план, как найти и проверить аномалии в числовых и категориальных колонках (**Fare, Age, SibSp, Parch, Embarked, Ticket**). Мне важно: что считать «аномалией» именно в этом датасете, какие проверки сделать, и что делать, если аномалии подтверждаются. Отвечай по пунктам, без кода.

Ответ LLM:

- **Что считать аномалией:** для числовых — экстремальные значения относительно класса (**Fare**), нереалистичные **Age** (отрицательные), очень большие семьи (**SibSp**=8+). Для категориальных — значения вне ожидаемого множества (**Embarked** вне S/C/Q), мусорные форматы в **Ticket**.
- **Проверки:** гистограммы и boxplot для числовых колонок; топ-N строк по значению; сопоставление **Fare** с **Pclass**; проверка **Age** на логичность (≥ 0 , не > 120).
- **Что делать:** явная ошибка → заменить на пропуск и иммутировать; редкий, но корректный случай (дорогой билет в 1 классе) → не удалять, логарифмировать **Fare**; пропуски не случайны → иммутировать по группам + добавить флаг **Age_is_missing**.

Мой комментарий:

Понравилась ключевая мысль — разделять «это ошибка» и «это редкий, но реальный случай», а не чистить всё подряд. Из реальных данных я знаю, что в **Fare** максимальное значение 512.33 — это действительно огромный выброс при среднем ~32 и медиане ~14.5. Скорее всего, это корректные данные для пассажиров 1 класса с дорогими каютами, поэтому удалять их было бы ошибкой. По **SibSp** максимум в датасете равен 8 — это большая семья, но исторически реальная. В следующем промпте я бы уточнил конкретные пороги для **Fare** через квантили внутри каждого класса, а не глобально — это даст более осмысленные границы «нормального» диапазона. Также стоило попросить LLM объяснить, как проверить, случайны ли пропуски в **Age**, например через сравнение среднего возраста между строками с пропуском и без.

Промпт 4: Формулировка бизнес-выводов

Текст промпта:

Представь, что я делаю короткий аналитический вывод по Titanic для не-технической аудитории (менеджер/преподаватель). На основе EDA (выживаемость выше у женщин и 1 класса, возраст и семейный статус тоже влияют) сформулируй 4–6 «бизнес-выводов» и 3 рекомендации, но так, чтобы: не было ложной причинности, было понятно, какие факторы самые сильные, и где ограничения данных. Пиши по-русски, без кода.

Ответ LLM:

- **Самый сильный фактор — пол:** женщины выживали значительно чаще мужчин во всех классах. Женщины 1 класса — 0.97, мужчины 3 класса — 0.14.
- **Класс связан с выживанием:** пассажиры 1 класса выживали чаще, чем 2 и особенно 3 класса. Вероятное объяснение — различия в доступе к шлюпкам, но это остаётся гипотезой.
- **Возраст играет роль:** дети имеют более высокую долю выживших, однако **Age** пропущен у 177 строк (20%), что снижает уверенность в выводах.
- **Стоимость билета коррелирует с выживанием:** но **Fare** связана с классом, поэтому её вклад нельзя оценивать изолированно.
- **Данные неполные:** **Cabin** пропущен у 77% строк, данные исторически уникальны — прямой перенос выводов на другие ситуации ограничен.

Рекомендации:

- **(1)** Показывать результаты вместе с размерами групп и оговаривать неопределённость.
- **(2)** Использовать **Sex, Pclass, Age, FamilySize** как основу модели; аккуратно обрабатывать пропуски.
- **(3)** Формулировать выводы как «связан с», а не «приводит к».

Мой комментарий:

Формулировки получились аккуратные — нет категоричных причинно-следственных заявлений, и есть конкретные оговорки про пропуски с реальными цифрами (177 по **Age**, 77% по **Cabin**). Я бы добавил ещё один вывод про «смещение выборки»: мы видим только тех, кто был учтён в официальных списках пассажиров, а значит часть данных может быть систематически смещённой. Также в следующий раз попрошу LLM добавлять к каждому выводу конкретную цифру из данных — это делает вывод намного убедительнее для нетехнической аудитории, чем просто слова «значительно чаще». Наглядный пример уже есть в первом выводе: женщины 1 класса — 0.97, мужчины 3 класса — 0.14, и это сразу даёт ощущение масштаба разрыва.

